

1. 把预测写成矩阵

设计矩阵把所有样本排成行：

$$\hat{y} = X\theta$$
$$X : m \times n, \theta : n \times 1$$

一次矩阵乘法得到全部预测。

2. 残差变成目标函数

误差向量为 $r = X\theta - y$ 。

$$J(\theta) = \frac{1}{2} \|X\theta - y\|_2^2$$

平方损失让大误差付出更高代价。

3. 求梯度并更新

链式法则把残差拉回参数空间：

$$\nabla_{\theta} J = X^{\top} (X\theta - y)$$
$$\theta \leftarrow \theta - \alpha \nabla J$$

4. 也可以直接求解

令梯度为零：

$$X^{\top} X \theta = X^{\top} y$$
$$\theta^* = (X^{\top} X)^{-1} X^{\top} y$$

实际计算优先用线性求解器或伪逆。

5. 几何上是投影

最优预测 $X\theta^*$ 是 y 在 X 列空间上的投影。

$$X^{\top} (y - X\theta^*) = 0: \text{残差与每个特征方向正交。}$$

6. 两种方法怎么选

小而稠密：正规方程

大而稀疏：梯度法 无论选哪

种，都先检查维度、缩放和验证集误差。

一图总结 数据 $X, y \rightarrow$ 预测 $X\theta \rightarrow$ 残差 $r \rightarrow$ 梯度或正规方程 $\rightarrow$ 最小二乘解。