

1. 线性分数不是概率

先计算 $z = \theta^\top x$ ，它可以取任意实数。

$$h_\theta(x) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

Sigmoid 把分数压到 $(0, 1)$ 。

2. 用伯努利似然

标签 $y \in \{0, 1\}$ ：

$$\ell(\theta) = \sum_i [y_i \log h_i + (1 - y_i) \log(1 - h_i)]$$

训练就是最大化真实标签的概率。

3. 梯度仍很简洁

对数似然求导后：

$$\nabla \ell = X^\top (y - p)$$

“真实标签减预测概率” 决定修正方向。

4. Hessian 给出曲率

令 $W = \text{diag}(p_i(1 - p_i))$ ：

$$H = -X^\top W X$$

靠近 $p = 0.5$ 的样本权重更大。

5. Newton / IRLS 更新

利用曲率调整步长：

$$\theta \leftarrow \theta - H^{-1} \nabla \ell$$

它等价于反复求解一次加权最小二乘。

6. 先处理数值边界

完全可分时参数可能无限增大；加入正则化。计算损失时用 log-sum-exp，避免 $\log(0)$ 。

一图总结 线性分数 $\rightarrow$ Sigmoid 概率 $\rightarrow$ 伯努利似然 $\rightarrow$ 梯度与曲率 $\rightarrow$ Newton/IRLS。