

1. 先描述数据怎样生成

生成式模型分别学习先验与类条件分布：

$$p(y), \quad p(x | y)$$

最后再用 Bayes 公式反推类别。

2. GDA 的假设

两类数据各自服从高斯，并共享协方差：

$$x | y = k \sim \mathcal{N}(\mu_k, \Sigma)$$

3. 参数来自计数和均值

$$\phi = \frac{1}{m} \sum_i \mathbf{1}[y_i = 1]$$
$$\mu_k = \frac{\sum_i \mathbf{1}[y_i = k] x_i}{\sum_i \mathbf{1}[y_i = k]}$$

协方差汇总所有类内偏差。

4. 为什么边界是直线

比较两个类别的对数后验，二次项因共享 Σ 抵消：

$$\log \frac{p(y = 1 | x)}{p(y = 0 | x)} = w^\top x + b。$$

5. Naive Bayes 换一种分解

高维离散特征使用条件独立假设：

$$p(x | y) = \prod_j p(x_j | y)$$

在对数空间里，乘积变成求和。

6. 零频率必须平滑

$$\hat{\phi}_{j|y} = \frac{N_{j,y} + \alpha}{N_y + \alpha K}$$

拉普拉斯平滑避免一个未见词让整类概率归零。

一图总结 建模 $p(y)$ 与 $p(x | y)$ → 估计参数 → 比较对数后验 → 得到分类边界。