

1. 前向传播保存中间量

线性层与激活层交替：

$$\begin{aligned}Z^{[l]} &= W^{[l]} A^{[l-1]} + b^{[l]} \\A^{[l]} &= g(Z^{[l]})\end{aligned}$$

2. 从损失末端开始

先得到输出层梯度 $dA^{[L]}$ ，再逐层向前追溯。

反向传播不是“反着算输出”，而是传播损失对每个中间量的敏感度。

3. 激活层做逐元素乘法

$$dZ^{[l]} = dA^{[l]} \odot g'(Z^{[l]})$$

ReLU 只让前向为正的位置通过梯度。

4. 线性层产生三条梯度

$$\begin{aligned}dW^{[l]} &= dZ^{[l]} (A^{[l-1]})^\top \\db^{[l]} &= \sum dZ^{[l]} \\dA^{[l-1]} &= (W^{[l]})^\top dZ^{[l]}\end{aligned}$$

5. 形状是最好的单元测试

dW 必须与 W 同形， db 与 b 同形， $dA^{[l-1]}$ 与 $A^{[l-1]}$ 同形。

先查形状，再查数值。

6. 更新前做梯度检查

用有限差分比较解析梯度：

$$\frac{J(\theta + \epsilon) - J(\theta - \epsilon)}{2\epsilon}$$

只在小网络和双精度下检查。

一图总结 前向缓存 → 输出层误差 → 激活层局部导数 → 线性层三条梯度 → 参数更新。