

1. 先中心化

减去训练集均值：

$$x_c^{(i)} = x^{(i)} - \mu$$

否则第一主成分可能只是在追逐整体偏移。

2. 计算协方差

$$S = \frac{1}{m} X_c^\top X_c$$

对角线是各特征方差，非对角线描述共同变化。

3. 找最大方差方向

在单位长度约束下最大化投影方差：

$$\begin{aligned} \max_{\|u\|=1} u^\top S u \\ Su = \lambda u \end{aligned}$$

答案是最大特征值对应的特征向量。

4. 取前 k 个主成分

将前 k 个正交方向排成 U_k ：

$$z = U_k^\top (x - \mu)$$

原始 n 维样本被编码成 k 维坐标。

5. 投影还能重建

$$\hat{x} = \mu + U_k z$$

丢掉的方向越少，重建误差越小；PCA 同时最小化平方重建误差。

6. 用解释方差选 k

$$\text{EVR}(k) = \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^n \lambda_j}$$

只在训练集拟合 PCA，再用同一均值和主轴变换验证集。

一图总结 中心化 → 协方差 → 特征分解 → 选择前 k 个方向 → 投影与重建。