

1. MDP 定义决策环境

$$(\mathcal{S}, \mathcal{A}, P, R, \gamma)$$

Markov 性表示未来只需当前状态与动作。

2. 价值衡量长期收益

$$V^\pi(s) = \mathbb{E}_\pi[\sum_{t=0}^{\infty} \gamma^t r_t \mid s_0 = s]$$

3. Bellman 方程做一步分解

$$V^\pi(s) = \sum_a \pi(a \mid s) \sum_{s'} P(s' \mid s, a) [R + \gamma V^\pi(s')]$$

4. 最优价值取最佳动作

$$V^*(s) = \max_a \sum_{s'} P(s' \mid s, a) [R + \gamma V^*(s')]$$

5. 价值迭代直接逼近最优值

反复应用 Bellman 最优算子：

$$V_{k+1} = \mathcal{T}^* V_k$$

收敛后用贪心动作提取策略。

6. 策略迭代交替两步

策略评估：求 V^π

策略改进：对 V^π 贪心

策略稳定时停止。

一图总结 MDP $\rightarrow$ 策略价值 $\rightarrow$ Bellman 分解 $\rightarrow$ 最优价值 $\rightarrow$ 价值迭代或策略迭代。