

1. 连续状态不能枚举

当 $s \in \mathbb{R}^n$ 时，表格价值函数不可行。

需要函数逼近、采样或利用动力学结构。

2. 先学习或给定环境模型

$$s_{t+1} = f(s_t, a_t) + \epsilon_t$$

模型回答“执行动作后会到哪里”。

3. 用模拟生成轨迹

$$\tau = (s_0, a_0, r_0, \dots, s_T)$$

从模型反复采样可估计策略回报，但模型误差会沿时间累积。

4. Monte Carlo 估计价值

$$\hat{V}^{\pi}(s) = \frac{1}{N} \sum_{i=1}^N \sum_t \gamma^t r_t^{(i)}$$

样本越多方差越小，计算代价越高。

5. 函数逼近推广到未见状态

$$V_{\theta}(s) \approx V^{\pi}(s)$$

线性基函数、神经网络都可使用，但训练目标与数据分布必须匹配。

6. 模型偏差需要监控

短期预测准不代表长期规划准。比较真实与模拟的多步状态、奖励和约束违例，限制规划视野。

一图总结 连续状态 → 动力学模型 → 模拟轨迹 → 价值估计 → 函数逼近 → 模型误差诊断。