

1. 指标不是目标本身

当代理指标成为优化目标，它可能不再代表真实目标。
先写清谁获益、谁承担错误成本。

2. 数据不是中立样本

采集机制决定谁被看见、怎样被标注。

$$p_{train}(x, y) \neq p_{deploy}(x, y)$$

分布偏差会复制到模型。

3. 历史标签可能含有偏见

标签常记录过去决策而非客观真相。高拟合度可能只是更准确地复制历史制度。

4. 总体指标会隐藏群体差异

$$R = \sum_g P(g) R_g$$

必须同时报告关键群体、交叉群体和罕见失败模式。

5. 反馈回路改变未来数据

模型输出影响行动，行动改变后续观测。

预测 → 决策 → 环境变化 → 新训练数据

6. 治理是持续流程

用途边界

人工复核

申诉机制

审计与退出

不是一次公平性指标就能结束。

一图总结 目标审查 → 数据与标签审查 → 分群评价 → 反馈回路 → 人工与制度治理。