


$$dW^{[l]} = \frac{1}{m} dZ^{[l]} (A^{[l-1]})^\top, \quad dA^{[l-1]} = (W^{[l]})^\top dZ^{[l]}$$

反向传播把上游梯度分别收缩到参数空间和前一层表示空间



轴 参数梯度沿样本轴 m 聚合；输入梯度沿当前层通道轴 n_l 收缩。

对象 dZ 是激活前值的上游梯度， dW 与参数同形， $dA^{[l-1]}$ 与前一层表示同形。

机制 同一个 dZ 有两个消费者：一条支路累计参数梯度，另一条把误差信号传回更早层。

线性层反向传播的两条收缩路径