


$$a_t \sim \pi(\cdot \mid s_t), \quad s_{t+1} \sim P(\cdot \mid s_t, a_t), \quad G_t = \sum_{k \geq 0} \gamma^k r_{t+k}$$

强化学习的数据不是固定表格，而是策略与环境交互后按时间顺序产生的轨迹



轴 B 是轨迹批次，T 是时间轴，ds 是状态特征；回报沿未来时间做折扣扫描而非无序平均。

对象 动作是离散 ID 或连续控制，奖励是即时标量，回报是依赖未来的累计随机变量。

机制 策略改变访问到的状态分布，因此探索与利用不能像监督学习那样假设数据独立同分布。