


$$(I - \gamma P_\pi) V^\pi = R_\pi, \quad \pi^+(s) = \arg \max_a [R(s, a) + \gamma P_a V^\pi]$$

策略迭代交替精确/近似评估当前策略，再用动作价值逐状态改进策略



轴 S 是状态轴，A 是动作轴；策略评估只保留状态价值，策略改进临时展开动作轴。

对象 V 与 Q 是价值分数，pi 是每状态的离散动作选择；不能把 $\arg \max$ 结果当作价值。

机制 每次贪心改进都不降低策略价值；有限 MDP 中反复评估与改进最终到达最优策略。