


$$y_i = \max_a \left[R(s_i, a) + \gamma \frac{1}{M} \sum_{j=1}^M V_\theta(s'_{ij}) \right], \quad \theta^+ = \arg \min_\theta \sum_i (V_\theta(s_i) - y_i)^2$$

拟合价值迭代用模拟下一状态构造 Bellman 监督目标，再把目标回归到函数近似器



轴 A 是动作轴， M 是模拟样本轴， d 是状态维度， p 是价值函数参数维度。

对象 S' 是模型产生的随机下一状态， y 是停止梯度的 Bellman 回归目标。

机制 先沿模拟轴估计期望，再沿动作轴取最大；回归误差、采样误差和模型偏差会分别累积。